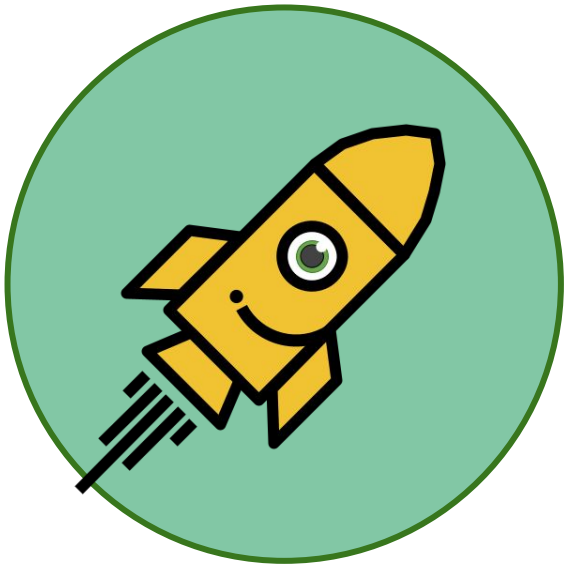


Analyse exploratoire et interprétation métier

Des données à la décision

2 jours · 14 h

Python · Colab

Plotly · Fairlearn

Qui suis-je et ma vision de la pédagogie

Imad, Chef de Projet IA et Enseignant



Mon mail Pro
imad.hatem417@gmail.com

Mon LinkedIn
linkedin.com/in/imadhatem417/

Actuellement Ingénieur Pédagogique chez Le Wagon

Formé plus de 300 élèves

96% de validation de diplôme RNCP6 | Bac+4

4,8/5 en satisfaction étudiante

Pédagogie humaine et Interactive, inspirée du jeu vidéo

Fondateur du site de formation
Ideonaut.com

Consulting et Formations pour

france•tv
SORBONNE UNIVERSITÉ
WILD CODE SCHOOL
LONGCHAMP PARIS
EduGroupe Accompagner pour réussir
Bellecour École

Bienvenue à bord

Cinq compétences du bloc BC2 à valider

C2.6 · Analyser

Univarié, bivarié, séries temporelles : tendances, patterns, signaux faibles.

C2.7 · Visualiser

Des graphiques et un dashboard lisibles et accessibles, pour tous les profils.

C2.8 · Détecter les biais

Représentativité et disparités, avec Fairlearn.

C2.9 · Restituer

Adapter le support et le discours à chaque partie prenante.

C2.10 · Recommander

Des actions exploitables, avec indicateurs ESG et limites.



Le programme des deux jours

Quatre séquences, trois livrables

JOUR 1

Analyser

9h00

Analyser et visualiser

13h30

Biais et approfondissement

Livrable Notebook versionné sur Git

JOUR 2

Communiquer

9h00

Visualisation et dashboard

13h30

Recommandations et restitution

Livrable Dashboard HTML, puis oral

Trois commanditaires

Un brief et un jeu de données chacun

Maison Lumen

Commerce · marketing

Refonte du site en 2024, offres personnalisées par algorithme : qu'est-ce qui a vraiment changé, et pour qui ?

Crédit Azur

Banque · risques

Nouveau score de crédit en 2024 : la production baisse, les jeunes actifs se plaignent.

Les Escales

Hôtellerie · commercial

Six hôtels, les Jeux olympiques, un nouveau moteur de réservation et des surclassements contestés.

Données fictives : réalistes, avec leurs défauts, et des biais à découvrir. Plusieurs groupes peuvent traiter le même secteur.

Livrables et évaluation

À chaud, par une restitution orale

Le notebook

Jour 1 · 17h00

Complet, commenté, versionné sur GitHub. Chaque choix justifié en markdown.

Le dashboard

Jour 2 · 12h30

Plotly, exporté en HTML autonome, avec les alertes sur les biais.

La restitution

Jour 2 · 14h30

15 minutes d'oral et 5 minutes de questions, notées sur 20.

La grille : une note par compétence, de C2.6 à C2.10. Elle vous est montrée dès maintenant.



Les outils

Tout dans Google Colab, et GitHub

pandas et NumPy

Charger, nettoyer, regrouper, agréger par mois.

Matplotlib et Seaborn

Les graphiques d’analyse.

statsmodels

Décomposition saisonnière des séries.

Plotly

Graphiques interactifs et dashboard HTML.

Fairlearn

Mesurer les disparités entre groupes.

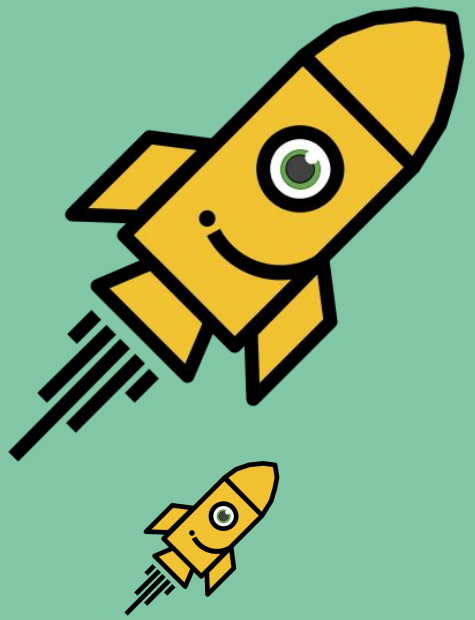
GitHub

Versionner le notebook depuis Colab, étape par étape.

Jour 1

Analyser les données

Séquences 1 et 2 · 9h00 – 17h00

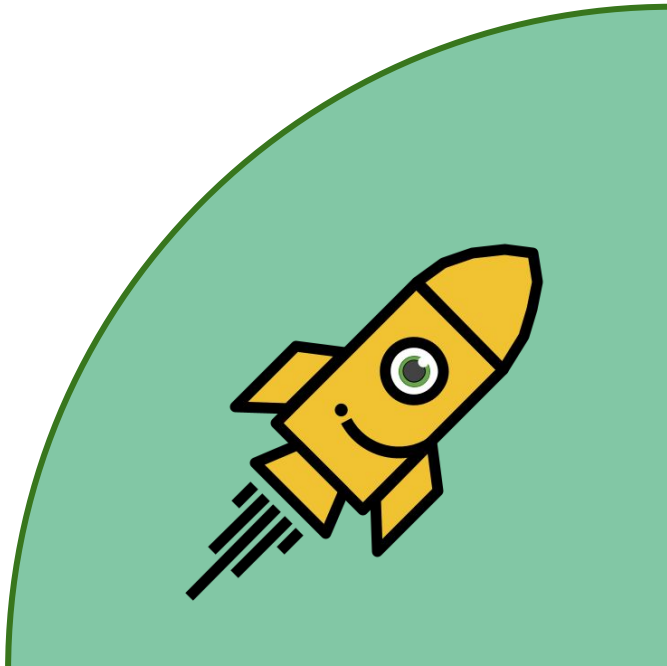


SÉQUENCE 1

Analyser et visualiser

9h00 – 12h30 · 3 h 30

Explorer en autonomie, puis analyser une variable, deux variables, et le temps.





Exploration autonome

30 minutes, sans consignes techniques

9h15 · Atelier

1. Lire le brief de votre secteur.
2. Ouvrir les données, comme vous voulez.
3. Repérer ce que représente une ligne.
4. Lister les problèmes de qualité.
5. Formuler trois hypothèses.

Questions à la fin

- Une ligne, c'est quoi ?
- Quelles variables comptent pour le commanditaire ?
- Quelles hypothèses testez-vous aujourd'hui ?

Livrable vos trois hypothèses écrites dans le notebook, puis un premier commit



Le diagnostic rapide

Six questions avant toute analyse

9h45 · Cours

Question	Commande	Ce qu'on cherche
Que représente une ligne ?	df[id].is_unique	une commande, une demande, une réservation
Quelle période ?	df[date].min(), .max()	des mois manquants, une fin tronquée
Des doublons ?	df.duplicated().sum()	une double saisie
Des valeurs manquantes ?	df.isna().mean()	et surtout : où manquent-elles ?
Des valeurs impossibles ?	df.describe(include='all')	un âge de 17 ans, un montant négatif
Quels types ?	df.dtypes	des dates lues comme du texte

Le piège : des valeurs qui manquent surtout dans un groupe ne manquent pas au hasard. C'est déjà un biais.



L’analyse univariée

Décrire une variable à la fois

9h50 · Cours

Type de variable	Indicateurs	Graphique
Numérique	moyenne, médiane, écart-type, quantiles, asymétrie	histogramme, boîte à moustaches
Catégorielle	effectifs et parts	barres horizontales triées
Date	période couverte, volume par mois	courbe

Médiane ou moyenne ?

Un chiffre d’affaires est presque toujours asymétrique : la médiane décrit mieux le client typique.

L’échelle log

Quand quelques valeurs écrasent le graphique, passez en échelle logarithmique.



L’analyse bivariée

Choisir l’outil selon les deux types

9h55 · Cours

Croisement	Graphique	Mesure ou test
numérique × numérique	nuage de points, hexbin	corrélation de Spearman
catégorielle × numérique	boîtes à moustaches par groupe	Mann-Whitney (2 groupes), Kruskal-Wallis
catégorielle × catégorielle	tableau croisé en %, barres empilées	khi² d’indépendance

Ciblée : on ne croise pas tout avec tout. On part d’une hypothèse : « les clients du web dépensent plus ».

Prudence : avec 20 000 lignes, tout est « significatif ». Regardez aussi la taille de l’écart.

Exercice 02 · Univarié et bivarié

Tester vos hypothèses

10h00 · Atelier

1. Nettoyer le minimum, en le justifiant.
2. Décrire le chiffre d’affaires.
3. Répartir les variables sensibles.
4. Croiser CA et segment, puis deux catégories.
5. Faire deux graphiques pour deux publics.

Repères

- Un verdict par hypothèse
- Un chiffre et un test pour chaque verdict
- Une cellule markdown par choix

Livrable le verdict sur vos trois hypothèses, appuyé sur des chiffres



Les séries temporelles

Trois composantes à séparer

11h00 · Cours

Tendance

L'évolution de fond, sur plusieurs années.

Saisonnalité

Le motif qui revient chaque année : soldes, fêtes, été.

Résidu

Ce qui reste : le bruit, et parfois un événement.

```python
from statsmodels.tsa.seasonal import seasonal_decompose
dec = seasonal_decompose(mensuel, model="multiplicative", period=12)
```

Additif ou multiplicatif ? multiplicatif si l'amplitude des pics grandit avec le niveau.



Lisser et comparer

Moyennes mobiles et croissance sur un an

11h05 · Cours

```python
mensuel = df.set_index("date")["montant"].resample("MS").sum()
mensuel.rolling(3, center=True).mean()     # lisse le bruit
mensuel.rolling(12, center=True).mean()    # montre la tendance
mensuel.pct_change(12)                      # croissance sur un an
```

3 mois

Garde les cycles, efface le bruit d'un mois isolé.

12 mois

Efface la saisonnalité : il reste la tendance.

Sur un an

Compare chaque mois au même mois de l'année précédente.



Détecter une rupture

Un changement de niveau durable

11h10 · Cours

1. Neutraliser les mois exceptionnels avant de décomposer.
2. Retirer la saisonnalité : série ÷ coefficient saisonnier.
3. Comparer, mois par mois, les 6 mois suivants aux 6 précédents.
4. Retenir l'écart le plus fort, et le tester.
5. Chercher le fait métier qui l'explique.

Pic ou rupture ?

- Un pic est ponctuel : les Jeux olympiques
- Une rupture dure : un nouveau site, un nouveau score
- Sans fait métier, pas de rupture

Rappel : la date détectée peut décaler d'un mois ou deux : délai de réservation, montée en charge.

Exercice 03 · Séries temporelles

Tendance, saisonnalité, rupture

11h20 · Atelier

1. Agréger le chiffre d'affaires par mois.
2. Ajouter les moyennes mobiles.
3. Décomposer, après les mois atypiques.
4. Tracer la croissance sur un an.
5. Localiser et expliquer la rupture.

Repères

- Les coefficients saisonniers en chiffres
- La date de l'événement du brief
- Les parts des segments par trimestre

Livrable trois conclusions chiffrées : saisonnalité, rupture, explication



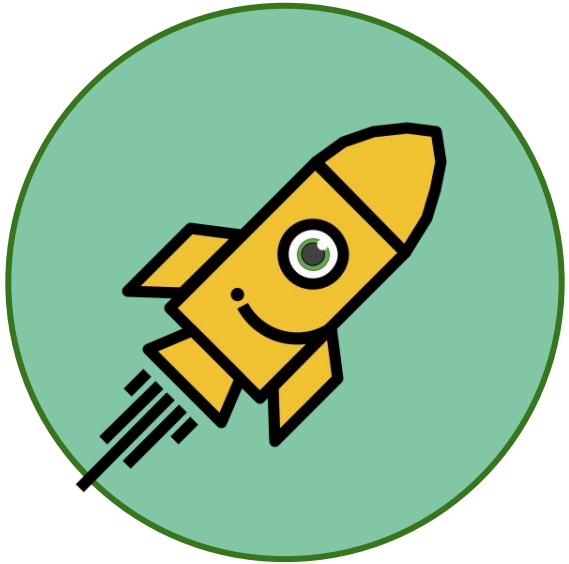
Une visualisation par profil

Un résultat, trois façons de le montrer

12h20 · Cours

Profil	Ce qu'il cherche	Visualisation adaptée
Équipe data	la distribution, les écarts, les incertitudes	boîtes, nuages, tableaux détaillés
Décideurs	un message, un chiffre, une tendance	une courbe ou des barres, un titre qui conclut
Conformité	qui est concerné, de combien	taux par groupe, seuils, effectifs

Le test : montrez le graphique dix secondes à quelqu'un : peut-il dire ce qu'il a compris ?



Déjeuner

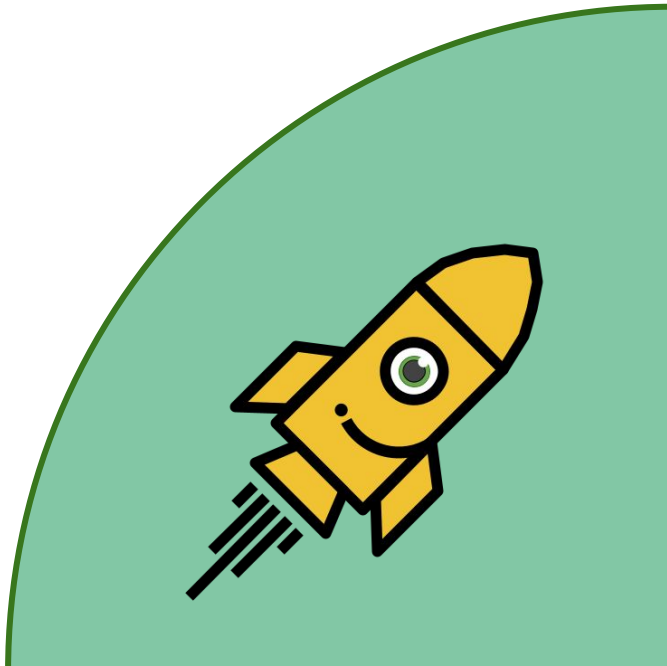
Reprise à 13h30

SÉQUENCE 2

Biais et approfondissement

13h30 – 17h00 · 3 h 30

Repérer les biais structurels, les mesurer avec Fairlearn, et dire les limites.





Les biais structurels

Six familles à chercher dans vos données

13h30 · Cours

Représentation

Certains groupes sont rares ou absents des données.

Mesure

La variable mesurée n’est qu’un indicateur approché.

Historique

Les décisions passées étaient déjà inégales.

Sélection

On n’observe le résultat que pour une partie des cas.

Proxy

Une variable neutre en apparence reproduit une variable sensible.

Agrégation

Un écart global s’inverse quand on regarde par groupe.



La représentativité

Comparer l’échantillon à une référence

13h35 · Cours

Tranche d’âge	Part dans les données	Part de référence	Ratio	Statut
25-34 ans	29 %	15 %	1,93	sur-représenté
45-54 ans	16 %	17 %	0,94	conforme
65 ans et plus	6 %	26 %	0,23	sous-représenté

Repères : ratio inférieur à 0,8, sous-représenté ; supérieur à 1,25, sur-représenté. Ce sont des conventions, pas des lois.

Attention : comptez les clients uniques, pas les lignes. Et choisissez la bonne référence : la population, ou la clientèle visée ?

Mesurer avec Fairlearn

Le taux de décision favorable par groupe

13h40 · Cours

```python
from fairlearn.metrics import (MetricFrame, selection_rate,
    count, demographic_parity_ratio)

mf = MetricFrame(
    metrics={"taux": selection_rate, "effectif": count},
    y_true=df["decision"], y_pred=df["decision"],
    sensitive_features=df["tranche_age"])
mf.by_group

demographic_parity_ratio(df["decision"], df["decision"],
    sensitive_features=df["tranche_age"])
```

Trois mesures

- Écart de parité : meilleur taux moins le plus faible
- Ratio de parité : plus faible ÷ meilleur
- Égalité des chances : taux de vrais positifs par groupe

Règle des quatre cinquièmes : un ratio sous 0,8 alerte. Repère américain, utile pour trier, sans valeur légale en France.



Lire une disparité

Trois questions avant de conclure

13h50 · Cours

À segment égal ?

Si l'écart fond quand on compare dans un même canal, le canal sert de proxy.

Depuis quand ?

Comparez avant et après l'événement du brief : un nouveau modèle peut créer l'écart.

Sur quels résultats ?

Un résultat observé pour une partie des cas seulement fausse l'égalité des chances.

Une disparité n'est pas une preuve : elle déclenche une enquête. Un critère de risque légitime peut l'expliquer en partie, pas forcément en totalité.



Les outils et le cadre

Fairlearn, AIF360 et la réglementation

14h00 · Cours

	Fairlearn	AIF360
Origine	projet open source lancé par Microsoft	IBM, aujourd'hui Linux Foundation
Points forts	MetricFrame, simple, intégré à scikit-learn	plus de métriques et d'algorithmes de correction
Dans ce cours	mesurer les disparités	cité, à explorer ensuite

IA Act : l'évaluation de la solvabilité des personnes est un usage à haut risque : gestion des risques, qualité des données, contrôle humain, documentation.

RGPD : âge, genre ou origine sont des données à manier avec une finalité claire et le minimum nécessaire.



Les limites de l’analyse

À écrire noir sur blanc, dans le notebook

14h05 · Cours

La référence Nationale, approximative : est-ce la bonne population ?

Les manquants Ils ne manquent pas au hasard : par canal, par profil.

La sélection Le résultat n’est connu que pour une partie des cas.

La causalité Une corrélation ne prouve ni l’intention ni la cause.

Les effectifs Un groupe de 40 personnes donne un taux fragile.

Exercice 04 · Biais

Représentativité, parité, limites

14h15 · Atelier

1. Comparer les clients à la référence.
2. Mesurer la parité de la décision.
3. Croiser deux variables sensibles.
4. Comparer à segment égal, et dans le temps.
5. Écrire les limites de l'analyse.

Repères

- Clients uniques pour la représentativité
- Les « inconnus » forment un groupe
- Toujours l'effectif à côté du taux

Livrable la section biais du notebook, avec une conclusion par variable sensible

Le livrable du jour 1

Un notebook complet, versionné sur GitHub

16h30 · Cours

1. Fichier › Enregistrer une copie dans GitHub
2. Autoriser Colab, choisir le dépôt du groupe
3. Écrire un message de commit qui dit ce que vous avez appris

Un bon notebook

- Une question par section
- Un choix, une cellule markdown qui le justifie
- Exécutable de haut en bas

Un bon commit : dit ce que vous avez appris, pas ce que vous avez tapé. « Saisonnalité : pic de décembre » plutôt que « modif ».

Livrable notebook enregistré dans GitHub à 17h00, lien du dépôt envoyé au formateur



Débrief du jour 1

Ce que disent vos données

16h50 · Échange

Une tendance

Et sa saisonnalité, chiffrée.

Une rupture

Datée, et expliquée par un fait.

Un biais

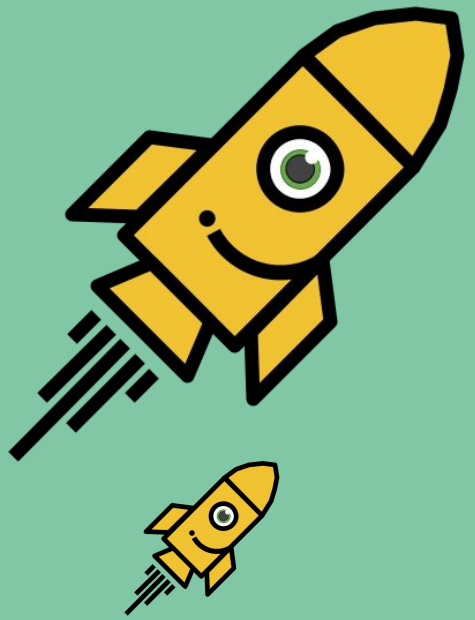
Mesuré, et ses limites.

Demain : on transforme ces résultats en dashboard, puis en recommandations défendues à l'oral.

Jour 2

Communiquer et recommander

Séquences 3 et 4 · 9h00 – 17h00

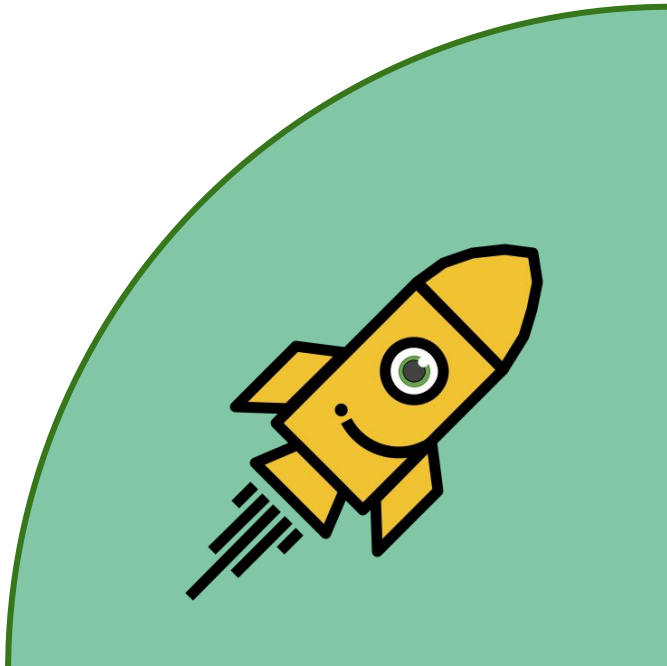


SÉQUENCE 3

Visualisation et dashboard

9h00 – 12h30 · 3 h 30

Des visualisations analytiques et communicantes, puis un dashboard Plotly qui intègre les biais.





Analytique ou communicante ?

Deux visualisations, deux usages

9h00 · Cours

Analytique

pour l'équipe data

- Explorer, comparer, vérifier
- Beaucoup d'information par graphique
- Interactive, filtrable
- Le titre décrit

Communicante

pour les décideurs

- Un message par graphique
- Une couleur d'accent, le reste en gris
- Des chiffres annotés
- Le titre conclut

Exemple de titre qui conclut : « Le web porte toute la croissance depuis avril 2024 », plutôt que « CA par canal ».



Des visualisations accessibles

Lisibles par tous, daltoniens compris

9h05 · Cours

1. Une palette sûre pour les daltoniens : Okabe-Ito, viridis.
2. Jamais la couleur seule : un texte, une forme, une étiquette.
3. Un contraste suffisant et des textes d’au moins 12 points.
4. Un titre qui dit la conclusion, des axes avec leurs unités.
5. Une description courte sous chaque graphique.



Plotly en pratique

Interactif, puis exporté en HTML

9h10 · Cours

```python
import plotly.express as px, plotly.graph_objects as go

fig = px.line(serie, x="date", y="CA", title="Le web porte la croissance")
kpi = go.Figure(go.Indicator(mode="number+delta", value=702,
                             delta={"reference": 658, "relative": True}))
fig.write_html("dashboard.html", include_plotlyjs=True)   # autonome
```



Interactif

Survol, zoom, légende cliquable, sans une ligne de plus.



Autonome

include_plotlyjs=True : le fichier s'ouvre sans connexion.



L’anatomie du dashboard

Du message au détail

9h15 · Cours

1 Chiffres clés

trois indicateurs, avec l’évolution

2 Tendance

la courbe et l’événement annoté

3 Alertes

les biais, écrits en clair

4 Représentativité

le ratio par groupe et les seuils

5 Parité

le taux de décision par groupe

6 Annexe data

le détail par segment

Ordre de lecture : du plus important au plus détaillé. Le décideur s’arrête après le bloc 3.

Intégrer les biais

Un indicateur et des alertes

9h20 · Cours

```python
rep = px.bar(representativite, x="modalite", y="ratio",
             color="statut", facet_col="variable",
             color_discrete_map={"sous-représenté": "#D55E00",
                                 "conforme": "#999999",
                                 "sur-représenté": "#0072B2"})
rep.add_hline(y=0.8, line_dash="dash")
rep.add_hline(y=1.25, line_dash="dash")
```

⚠ Points de vigilance

- 65 ans et plus : sous-représentés, ratio 0,23
- Offres personnalisées : 3 fois moins envoyées aux 65 ans et plus

L'alerte s'écrit : un lecteur daltonien ou pressé doit la comprendre sans voir la couleur.

Exercice 05 · Dashboard Plotly

Un fichier HTML autonome et partageable

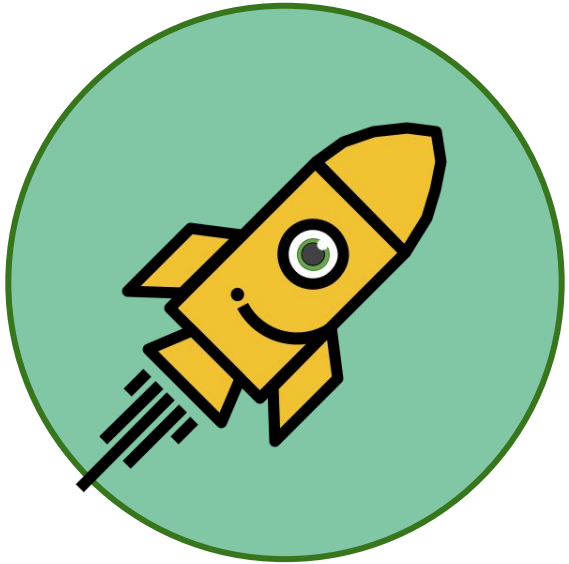
9h45 · Atelier

1. Créer trois indicateurs clés.
2. Tracer la tendance avec l'événement.
3. Ajouter l'indicateur de représentativité.
4. Ajouter la parité de la décision.
5. Écrire les alertes, exporter en HTML.

Check-list

- S'ouvre sans connexion
- Un titre qui conclut par graphique
- Alertes écrites, palette Okabe-Ito

Livrable dashboard_<secteur>.html, envoyé au formateur à 12h30



Déjeuner

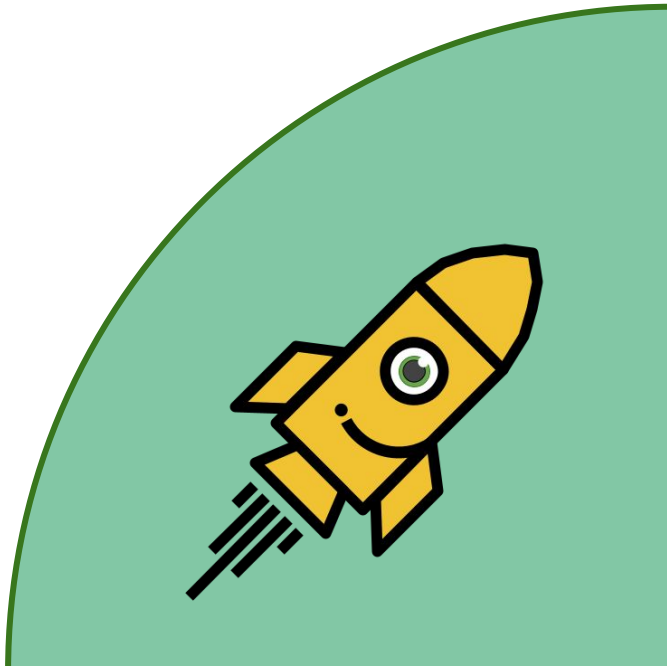
Reprise à 13h30

SÉQUENCE 4

Recommandations et restitution

13h30 – 17h00 · 3 h 30

Formuler des recommandations exploitables, les défendre en 15 minutes, puis débriefer ensemble.





Une recommandation exploitable

Cinq éléments, toujours les mêmes

13h30 · Cours

Constat chiffré	Recommandation	Impact attendu	Indicateur de suivi	Limite
Les 65 ans et plus reçoivent 3 fois moins d'offres	Ajouter un canal hors ligne au ciblage	Ratio de parité au-dessus de 0,8	Ratio de parité, chaque trimestre	Le canal n'explique qu'une partie de l'écart

SMART : spécifique, mesurable, atteignable, réaliste, daté. « Améliorer l'expérience client » n'est pas une recommandation.

Trois à cinq : pas plus. Classées par impact, avec une décision à prendre pour chacune.

Ce que la recommandation intègre

Au-delà du chiffre d’affaires

13h35 · Cours

Les indicateurs ESG

Retours et transport, inclusion financière, part des réservations directes, équité des décisions.

Les retours utilisateurs

Plaintes, avis, remontées du terrain : ils confirment ou nuancent les chiffres.

Les limites

Ce que l’analyse ne permet pas de dire, et ce qu’il faudrait collecter.

Pour un cas d’usage IA : la recommandation peut être d’ajuster le modèle, de le surveiller, ou de ne pas le généraliser.



Adapter le discours

Chaque interlocuteur sa question

13h40 · Cours

Interlocuteur	Sa question	Ce que vous lui montrez
Direction métier	Que faire lundi ?	les recommandations, leurs indicateurs, le calendrier
Décideurs	Combien, et quel risque ?	trois chiffres clés, la tendance, la décision attendue
Conformité	Est-ce équitable et documenté ?	représentativité, parité, limites, mesures correctives

Vulgariser : « sur 100 demandes de moins de 25 ans, 8 sont accordées, contre 83 entre 55 et 64 ans » parle plus qu'un ratio de 0,09.



Raconter les données

15 minutes, une histoire

13h45 · Cours

1 min	3 min	3 min	3 min	4 min	1 min
Contexte	**Tendance**	**Segments**	**Biais**	**Actions**	**Décision**
la question du commanditaire	saisonnalité et rupture	ce qui porte l'activité	qui, combien, pourquoi	recommandations et indicateurs	ce que vous demandez

Situation, complication, résolution : ce qui se passe, ce qui pose problème, ce que vous proposez. Puis 5 minutes de questions.



La grille de la restitution

Une note par compétence, sur 20

13h50 · Évaluation

Compétence	Ce qui est attendu	Points
C2.6 · Analyser	tendances, saisonnalité, rupture et segments, chiffrés et testés	4
C2.7 · Visualiser	dashboard lisible, accessible, titres qui concluent	4
C2.8 · Biais	représentativité, parité, proxy, limites	4
C2.9 · Restituer	discours adapté, clarté, temps tenu, réponses	4
C2.10 · Recommander	actions SMART, indicateurs ESG, limites	4
Total		**20**

Les restitutions

15 minutes, puis 5 minutes de questions

14h30 · Évaluation

Le groupe présente

Le dashboard en support, chacun prend la parole.

Le jury questionne

Tour à tour métier, décideur, conformité.

Le formateur note

Trois points forts, trois points à améliorer.

Les autres groupes : notent une idée à reprendre et une question à poser. Elles nourriront le débriefing collectif.



Le débriefing collectif

30 minutes pour prendre du recul

16h30 · Échange

Comparer les secteurs Mêmes méthodes, biais différents : qu'est-ce qui revient partout ?

Les meilleures idées Une visualisation, une recommandation, une formulation à garder.

Les pièges rencontrés Mois atypiques, données manquantes, proxys : qui s'y est fait prendre ?

Et en entreprise ? Qui décide de corriger un biais, et avec quel budget ?



Ce qu’il faut retenir

Cinq idées à emporter

16h55 · Échange

1. On part d’une question métier, pas des données.
2. Une tendance se lit sans la saisonnalité, une rupture s’explique par un fait.
3. Une disparité se mesure, à segment égal, et dans le temps.
4. Un graphique qui conclut, une alerte qui s’écrit.
5. Une recommandation a un chiffre, un indicateur et une limite.



Pour aller plus loin

Ressources de référence

statsmodels

statsmodels.org, séries temporelles

Plotly pour Python

plotly.com/python

Fairlearn

fairlearn.org, guide de l’utilisateur

AIF360

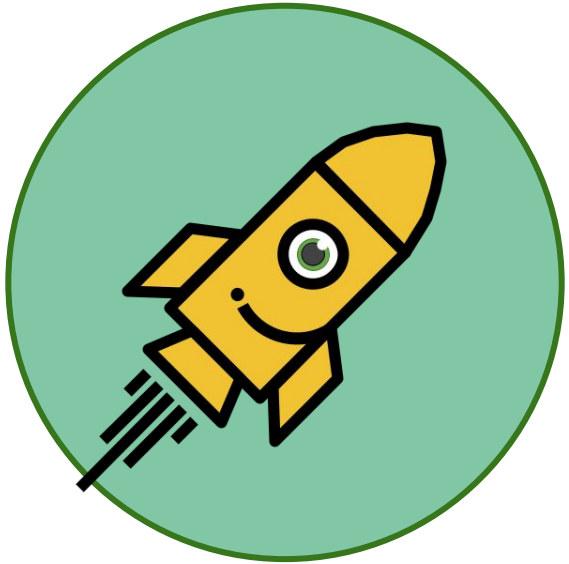
github.com/Trusted-AI/AIF360

Couleurs accessibles

palette Okabe-Ito, simulateurs de daltonisme

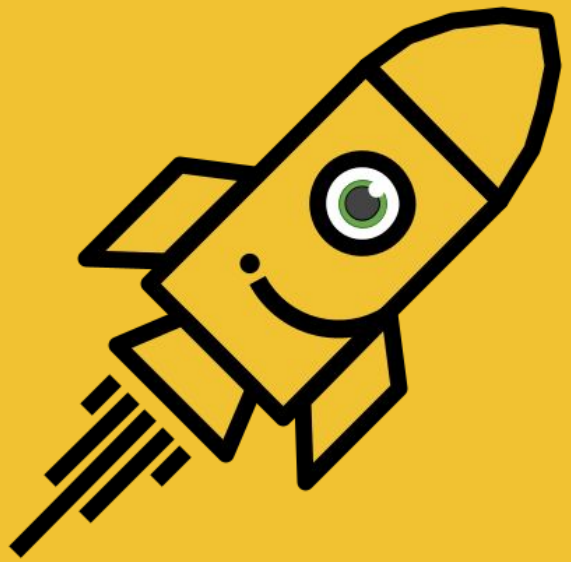
CNIL

cnil.fr, fiches intelligence artificielle



Merci !

Vos questions et vos retours



LANCEMENT

ÉMINENT !